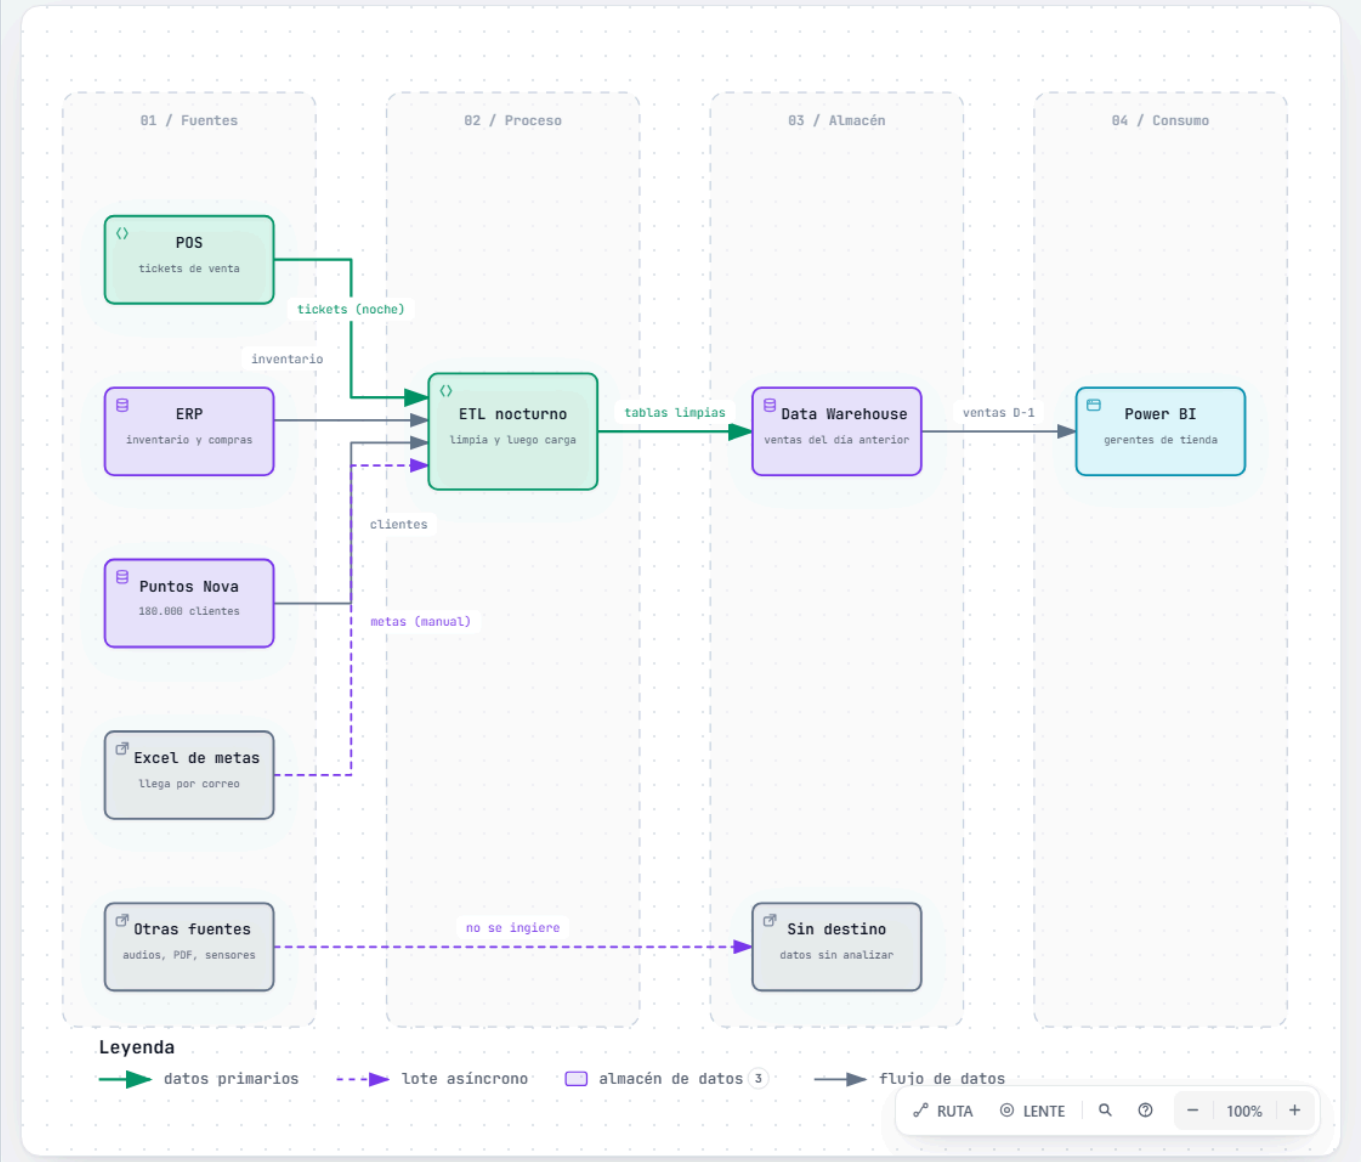
Taller 1 · Comité de arquitectura de RetailNova

Técnicas Avanzadas de Gestión de Datos · Semana 1
Maestría en Computación para Desarrollo de Apps Inteligentes
Integrantes: Julian Andres Quimbayo Castro (rol simulado: Arquitecto de Datos)
Presentado al Docente: Ing. Alexander Yela Reyes

Recomendación del comité. Mantener el Data Warehouse hoy, pasar a un Lakehouse con ingesta híbrida en el Año 2 y evolucionar a un Data Mesh en el Año 5, cuando haya equipo para operarlo.



RetailNova hoy: ETL nocturno hacia un data warehouse

Evidencia 1 · Actividad 1: fuentes de datos (15%)

#	Fuente	Forma	Ingesta	Complemento	★
1	Tickets de venta del POS	Estructurado	Streaming (o micro-batch de 5–15 min)	Batch nocturno de conciliación	★
2	Inventario del ERP	Estructurado	CDC	Snapshot semanal para cuadrar	
3	Fotos del catálogo en línea	No estructurado	Batch (al cargar)	—	
4	Reseñas y calificaciones (JSON)	Semiestructurado	Micro-batch por hora	—	★
5	Lecturas de temperatura de neveras	Semiestructurado	Streaming	Archivo batch en el lake para histórico	★
6	Audios del call center	No estructurado	Batch semanal	—	
7	Facturas de proveedores en PDF	No estructurado	Batch diario (con OCR)	—	
8	Clics y navegación en la tienda web	Semiestructurado	Streaming	Batch para sesionizar y agregar	
9	Clientes del programa de puntos	Estructurado	CDC	—	
10	Correos de reclamos	No estructurado	Batch / micro-batch	—	
11	Video de cámaras de seguridad	No estructurado	Batch de extractos o eventos	—	
12	Excel de metas comerciales	Estructurado	Batch mensual	—	
13	Logs del servidor web	Semiestructurado	Streaming (o batch por archivo)	—	
14	Menciones de la marca en redes (API)	Semiestructurado	Batch (consulta periódica de API)	—	
15	Precios y promociones vigentes	Estructurado	CDC	—	

Las tres estrellas

- **POS (tarjeta 1).** Es la fuente central: responde la pregunta A (qué se agota) y acorta el retraso de un día de los gerentes.
- **Sensores de neveras (tarjeta 5).** Responde la pregunta B y evita la pérdida de mercancía refrigerada; su valor se pierde si la alerta llega al día siguiente.
- **Reseñas de la tienda web (tarjeta 4).** Es la fuente más directa para la pregunta C sobre la marca Nova y alimentará el motor de recomendaciones.

Cómo llega cada tipo de dato

Forma de llegada	Fuentes	Por qué
CDC	ERP inventario, clientes de Puntos Nova, precios y promociones	Son bases relacionales: capturar cambios evita cargarlas completas cada noche.
Streaming	POS, sensores, clics, logs	El valor está en actuar en minutos o segundos (quiebre de stock, nevera dañada).
Micro-batch	Reseñas web	El tiempo real no aporta; cada hora basta.
Batch	Fotos, audios, PDF, correos, Excel de metas, redes, video	Llegan por lotes o su valor no depende de la inmediatez.

¿Qué tarjeta costó más? Las tarjetas 7 (facturas PDF) y 10 (correos de reclamos) fueron las más difíciles. Un PDF o un correo traen algo de estructura (campos, encabezados), pero su contenido útil es texto libre, así que los clasificamos como no estructurados. El Excel de metas (12) también dudó: es tabular, pero llega por correo y a mano, por eso lo tratamos como estructurado con ingesta batch manual.

Propuesta de ingesta híbrida

Ruta caliente. Streaming y CDC para POS, sensores, clics, inventario y precios. Alimenta las alertas de stock y de neveras en segundos.

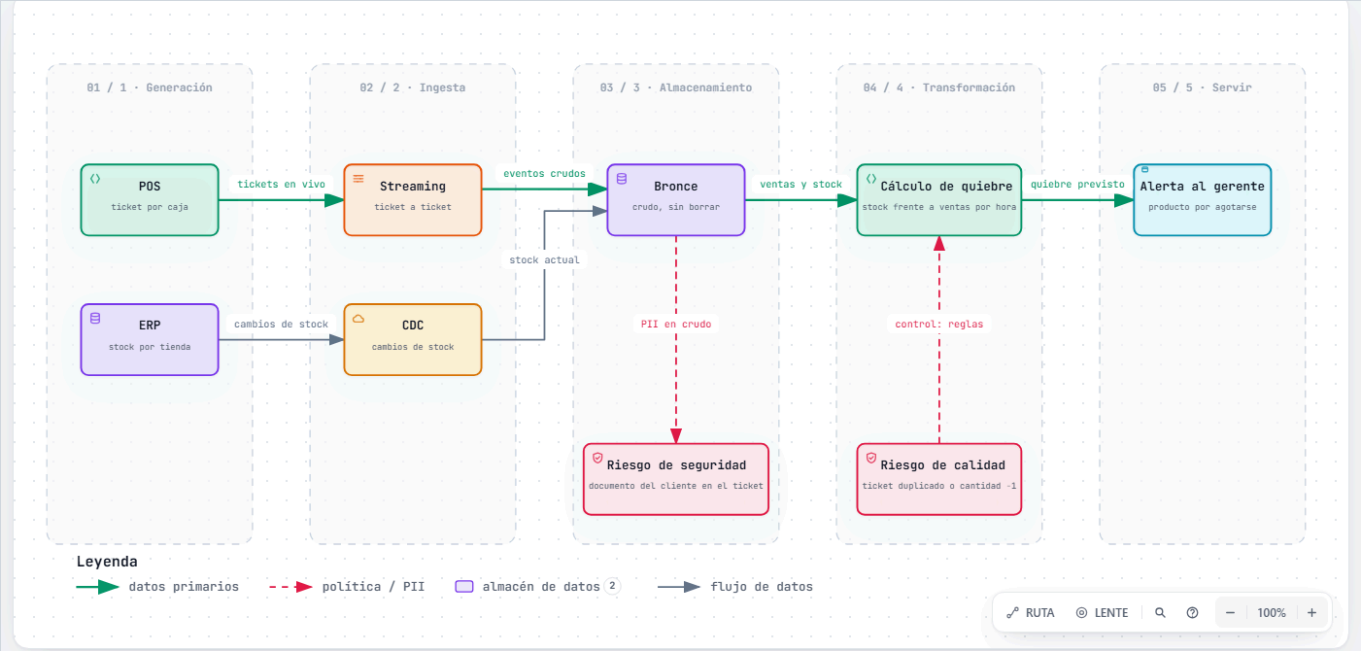
Ruta fría. Batch para archivos, texto y todo lo demás, más la conciliación de lo anterior. Guarda el histórico y corrige lo que llegó tarde o duplicado.

Ambas rutas aterrizan en el mismo almacenamiento crudo (bronce) y se transforman después con ELT, de modo que comparten reglas de limpieza.

Momento	Qué se activa
Hoy	Batch + CDC puntual en inventario y POS. Sin broker de eventos: el equipo de 4 personas no lo sostendría.
Año 2	Se agrega streaming con un broker para sensores y clics. Con tienda en línea y sensores en todas las neveras sí se justifica.
Año 5	Cada dominio opera sus propios pipelines bajo contratos de datos.

Evidencia 2 · Actividad 2: recorrido del dato (20%)

Pregunta A: ¿Qué producto se agota primero en cada tienda?

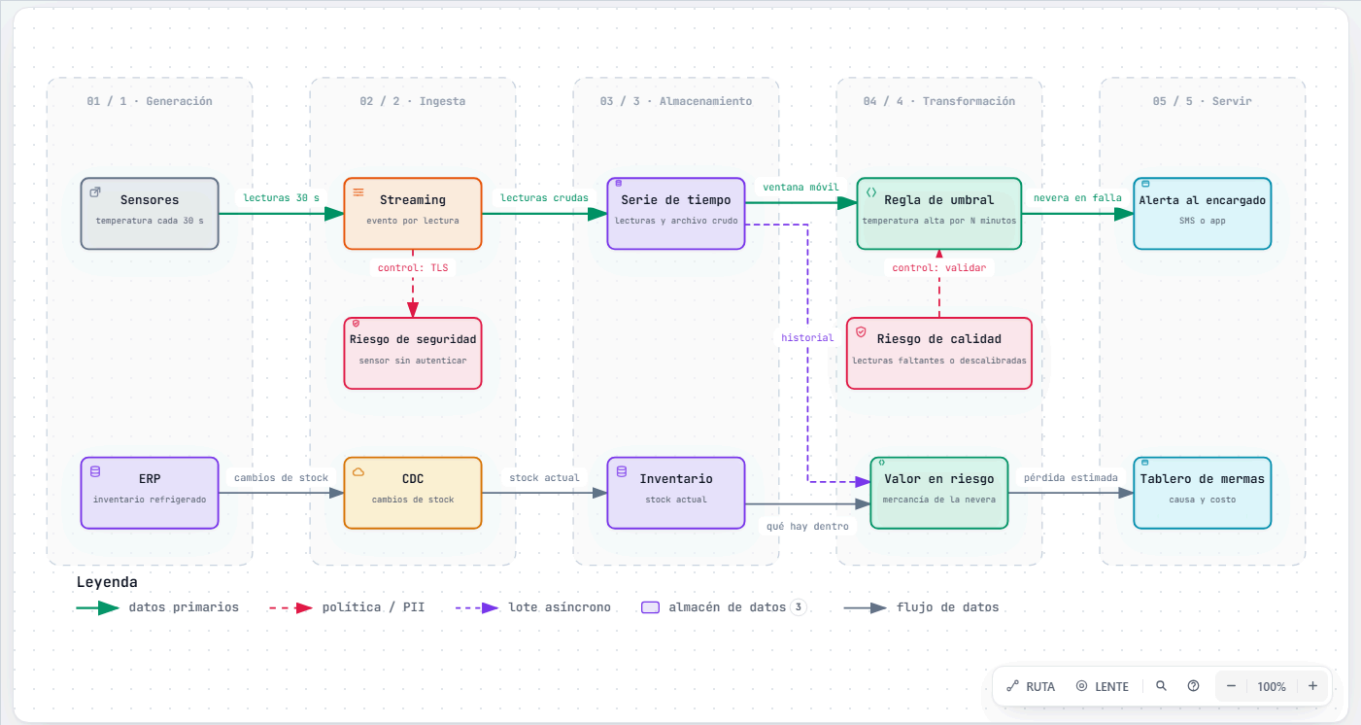


Recorrido A

Etapa	Qué pasa
Generación	Cada caja del POS genera un ticket por línea; el ERP mantiene el stock por tienda.
Ingesta	Los tickets entran por streaming (ticket a ticket); los cambios de stock entran por CDC sin cargar al ERP.
Almacenamiento	Todo aterriza crudo y sin borrar en la capa Bronce del lakehouse.
Transformación	Se calcula stock frente a ventas por hora y se proyecta el quiebre por producto y tienda (ELT).
Servir	El gerente recibe una alerta de producto por agotarse y el comprador ve el ranking.

Riesgo	Etapa de control	Descripción	Control
Calidad	Transformación	Tickets duplicados o con cantidad negativa distorsionan el quiebre.	Deduplicar por ticket y producto y validar cantidad > 0.
Seguridad	Almacenamiento	El ticket trae el documento del cliente (dato personal).	Enmascarar o seudonimizar al aterrizar y limitar el acceso.

Pregunta B: ¿Se están dañando productos por fallas en las neveras?

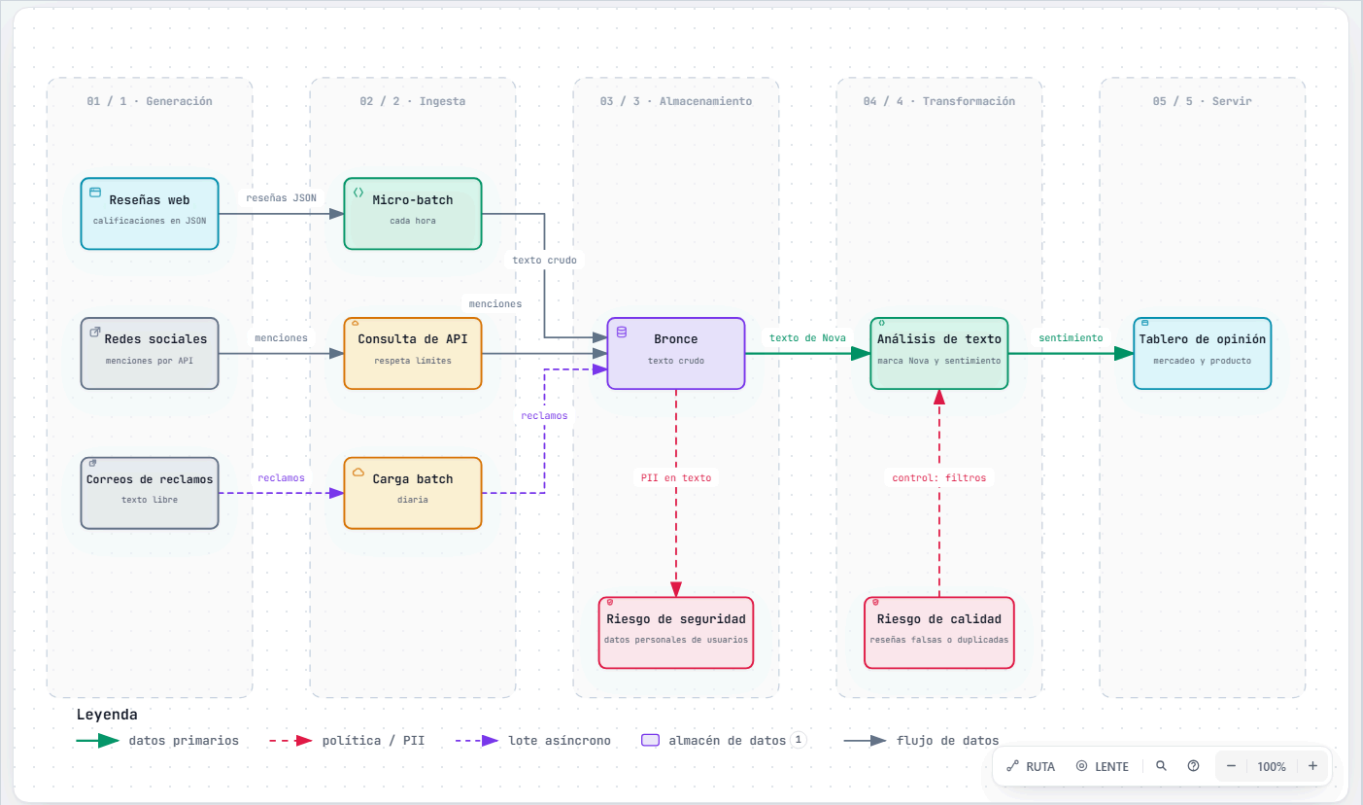


Recorrido B

Etapa	Qué pasa
Generación	Los sensores de las neveras envían temperatura cada 30 segundos.
Ingesta	Streaming en tiempo real para las lecturas; CDC para el stock refrigerado del ERP.
Almacenamiento	Serie de tiempo para lecturas recientes y archivo crudo para el histórico; inventario en Bronce.
Transformación	Regla de umbral con ventana móvil (temperatura alta durante N minutos) y cálculo del valor de mercancía en riesgo.
Servir	Alerta por SMS o app al encargado en segundos y tablero de mermas con causa y costo.

Riesgo	Etapa de control	Descripción	Control
Calidad	Transformación	Lecturas faltantes o un sensor descalibrado generan falsas alarmas o ceguera.	Validar completitud de lecturas y calibración antes de aplicar la regla.
Seguridad	Ingesta	Un sensor sin autenticar puede inyectar lecturas falsas.	TLS y credenciales por dispositivo en el punto de entrada.

Pregunta C: ¿Qué opinan los clientes de la nueva marca propia Nova?



Recorrido C

Etapa	Qué pasa
Generación	Los clientes escriben reseñas en la web, mencionan la marca en redes y envían reclamos por correo.
Ingesta	Reseñas en micro-batch horario; redes por consulta periódica de API; correos por carga batch diaria.
Almacenamiento	Todo el texto aterriza crudo en Bronce, sin perder el original.
Transformación	Se filtra lo referente a Nova y se analiza el sentimiento con procesamiento de lenguaje (NLP).
Servir	Mercadeo y producto consultan un tablero de opinión por producto Nova.

Riesgo	Etapa de control	Descripción	Control
Calidad	Transformación	Reseñas falsas o repetidas sesgan el sentimiento.	Filtrar duplicados y cuentas sospechosas antes del análisis.
Seguridad	Almacenamiento	Reseñas y menciones contienen datos personales de usuarios.	Anonimizar al aterrizar y respetar los límites de uso de cada API.

¿Cuál fue la más difícil? La pregunta C fue la más difícil. Las A y B se resuelven con números (stock, ventas, temperatura) y reglas claras. La C parte de texto libre, mezcla tres fuentes con ritmos distintos de llegada y exige análisis de lenguaje para convertir opiniones en una métrica, además de más cuidado con datos personales.

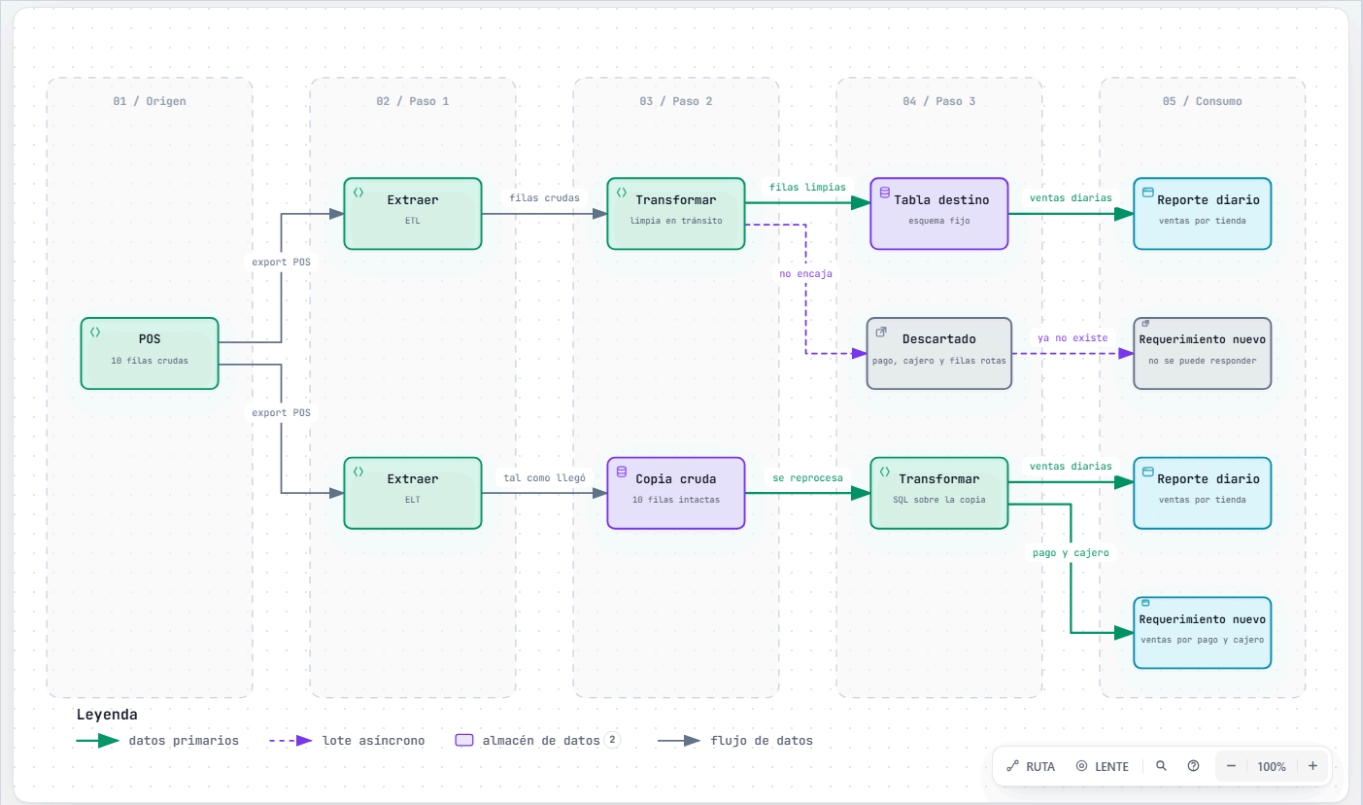
Evidencia 3 · Actividad 3: ETL vs ELT (25%)

Ventas crudas del POS (Anexo B)

Ticket	Fecha	Tienda	Producto	Cant.	Precio	Pago	Cajero
T-1001	2026-10-01	Cali Norte	Arroz 1 kg	2	4.200	Nequi	C-07
T-1002	01/10/2026	CALI NTE	Leche 1 L	3	$3.900	Efectivo	C-07
T-1003	2026-10-01	Palmira	Aceite 900 ml	1	12.500	Tarjeta débito	C-12
T-1003	2026-10-01	Palmira	Aceite 900 ml	1	12.500	Tarjeta débito	C-12
T-1004	Oct 1, 2026	Jamundí	Detergente 2 kg	1		Nequi	C-03
T-1005	2026-10-01	Cali Sur	Huevos x30	-1	15.800	Tarjeta crédito	C-05
T-1006	2026-10-02	Cali Norte	Café 500 g	2	18.900	Daviplata	C-07
T-1007	2026/10/02	cali sur	Pan tajado	1	6.300	Efectivo	
T-1008	2026-10-02	Tienda 13	Azúcar 1 kg	4	3.600	Nequi	C-09
T-1009	2026-10-02	Palmira	Gaseosa 1,5 L	200	5.500	Tarjeta crédito	C-12

Nuestras reglas de limpieza

#	Problema	Filas	Regla
1	Fechas en cuatro formatos distintos	T-1002, T-1004, T-1007	Convertir todo a ISO AAAA-MM-DD. Se asume día/mes (formato colombiano) en 01/10/2026.
2	Nombres de tienda inconsistentes	T-1002 (CALI NTE), T-1007 (cali sur)	Pasar a un catálogo oficial de 12 tiendas con tabla de alias (CALI NTE → Cali Norte).
3	Tienda que no existe	T-1008 (Tienda 13)	RetailNova tiene 12 tiendas: rechazar la fila o enviarla a cuarentena para revisión.
4	Fila duplicada	T-1003 (dos veces)	Deduplicar por ticket + producto + cantidad + hora; conservar una sola.
5	Precio faltante	T-1004	No inventar el valor: marcar nulo y, si se puede, completar desde la tabla de precios vigentes.
6	Cantidad negativa	T-1005 (-1)	Tratarla como devolución o anulación, nunca como venta negativa; validar con el ticket original.
7	Cantidad atípica	T-1009 (200 gaseosas)	Marcar valores fuera de rango (por ejemplo > 50 por línea) como posible error de digitación y revisar.
8	Cajero vacío	T-1007	Permitir nulo y registrar «sin cajero» para auditar la caja.
9	Formato de precio con símbolo y separador de miles	T-1002 ($3.900) y el resto (4.200)	Quitar $ y puntos y guardar el precio como entero en pesos.



ETL frente a ELT sobre las 10 filas del POS

Equipo ETL: tabla limpia final

fecha	tienda	ticket	producto	cantidad	precio_unit	valor_linea
2026-10-01	Cali Norte	T-1001	Arroz 1 kg	2	4200	8400
2026-10-01	Cali Norte	T-1002	Leche 1 L	3	3900	11700
2026-10-01	Palmira	T-1003	Aceite 900 ml	1	12500	12500
2026-10-02	Cali Norte	T-1006	Café 500 g	2	18900	37800
2026-10-02	Cali Sur	T-1007	Pan tajado	1	6300	6300

Descartado:

- **T-1003 (copia)**: duplicado
- **T-1004**: precio vacío
- **T-1005**: cantidad negativa
- **T-1008**: tienda inexistente
- **T-1009**: cantidad atípica
- **Columnas método_pago y cajero**: no caben en el esquema del reporte diario

Equipo ELT: copia cruda intacta y tabla limpia con estado

Ticket	Fecha	Tienda	Producto	Cant.	Precio	Valor	Pago	Cajero	Estado
T-1001	2026-10-01	Cali Norte	Arroz 1 kg	2	4200	8400	Nequi	C-07	válido
T-1002	2026-10-01	Cali Norte	Leche 1 L	3	3900	11700	Efectivo	C-07	válido
T-1003	2026-10-01	Palmira	Aceite 900 ml	1	12500	12500	Tarjeta débito	C-12	válido
T-1004	2026-10-01	Jamundí	Detergente 2 kg	1	—	—	Nequi	C-03	precio pendiente
T-1005	2026-10-01	Cali Sur	Huevos x30	-1	15800	-15800	Tarjeta crédito	C-05	devolución
T-1006	2026-10-02	Cali Norte	Café 500 g	2	18900	37800	Daviplata	C-07	válido
T-1007	2026-10-02	Cali Sur	Pan tajado	1	6300	6300	Efectivo	sin cajero	válido
T-1008	2026-10-02	Tienda 13 (?)	Azúcar 1 kg	4	3600	14400	Nequi	C-09	cuarentena
T-1009	2026-10-02	Palmira	Gaseosa 1,5 L	200	5500	1100000	Tarjeta crédito	C-12	revisar

Reporte diario de ventas por tienda

Fecha	Tienda	Ventas (COP)
2026-10-01	Cali Norte	20.100
2026-10-01	Palmira	12.500
2026-10-02	Cali Norte	37.800
2026-10-02	Cali Sur	6.300

Respuesta al requerimiento nuevo

Supuesto del taller (la guía no lo define): la gerencia pide ventas por método de pago y por cajero, para vigilar el efectivo en caja y las devoluciones.

Método de pago	Ventas válidas (COP)
Efectivo	18.000
Daviplata	37.800
Tarjeta débito	12.500
Nequi	8.400

Cajero	Ventas válidas (COP)
C-07	57.900

Cajero	Ventas válidas (COP)
C-12	12.500
sin cajero	6.300

ETL. Equipo ETL: no pudo responderlo. Su esquema se diseñó solo para ventas diarias por tienda, así que método de pago y cajero se descartaron antes de cargar y las devoluciones se rechazaron. Para responder habría que cambiar el esquema y volver a extraer los datos del POS.

ELT. Equipo ELT: sí pudo responderlo. Conservó las 10 filas crudas, así que bastó con una nueva transformación SQL sobre la copia, sin volver al POS. Además pudo mostrar la devolución de T-1005, que el ETL había descartado.

Lección. ETL (schema-on-write) da un destino limpio y barato de consultar, pero decide el esquema antes de conocer las preguntas futuras. ELT (schema-on-read) guarda primero y transforma después: más flexible y auditable, a cambio de más almacenamiento y gobierno sobre la capa cruda.

Evidencia 4 · Actividades 4 y 5: decisión (40%)

Anexo C · Matrices de decisión

Hoy

12 tiendas, solo venta física, 4 personas en datos, reportes de ventas para la gerencia.

Criterio	Data Warehouse	Data Lake	Lakehouse	Data Mesh
Tipos de dato que necesita la empresa	4	5	5	4
Reportes y BI confiables	5	2	4	3
Soporte para machine learning	3	4	4	3
Gobierno y calidad del dato	5	2	4	2
Costo de almacenamiento y cómputo	4	4	3	1
Tamaño del equipo que puede operarla	5	3	3	1
Autonomía de las áreas de negocio	2	3	3	5
Total	28	23	26	19

Arquitectura ganadora: Data Warehouse (28 puntos).

Año 2

Tienda en línea en marcha, clickstream web, motor de recomendaciones y sensores en todas las neveras.

Criterio	Data Warehouse	Data Lake	Lakehouse	Data Mesh
Tipos de dato que necesita la empresa	2	5	5	4
Reportes y BI confiables	5	2	4	3
Soporte para machine learning	2	5	5	4
Gobierno y calidad del dato	4	2	4	3
Costo de almacenamiento y cómputo	3	5	4	2
Tamaño del equipo que puede operarla	4	2	3	1
Autonomía de las áreas de negocio	2	3	3	5
Total	22	24	28	22

Arquitectura ganadora: Lakehouse (28 puntos).

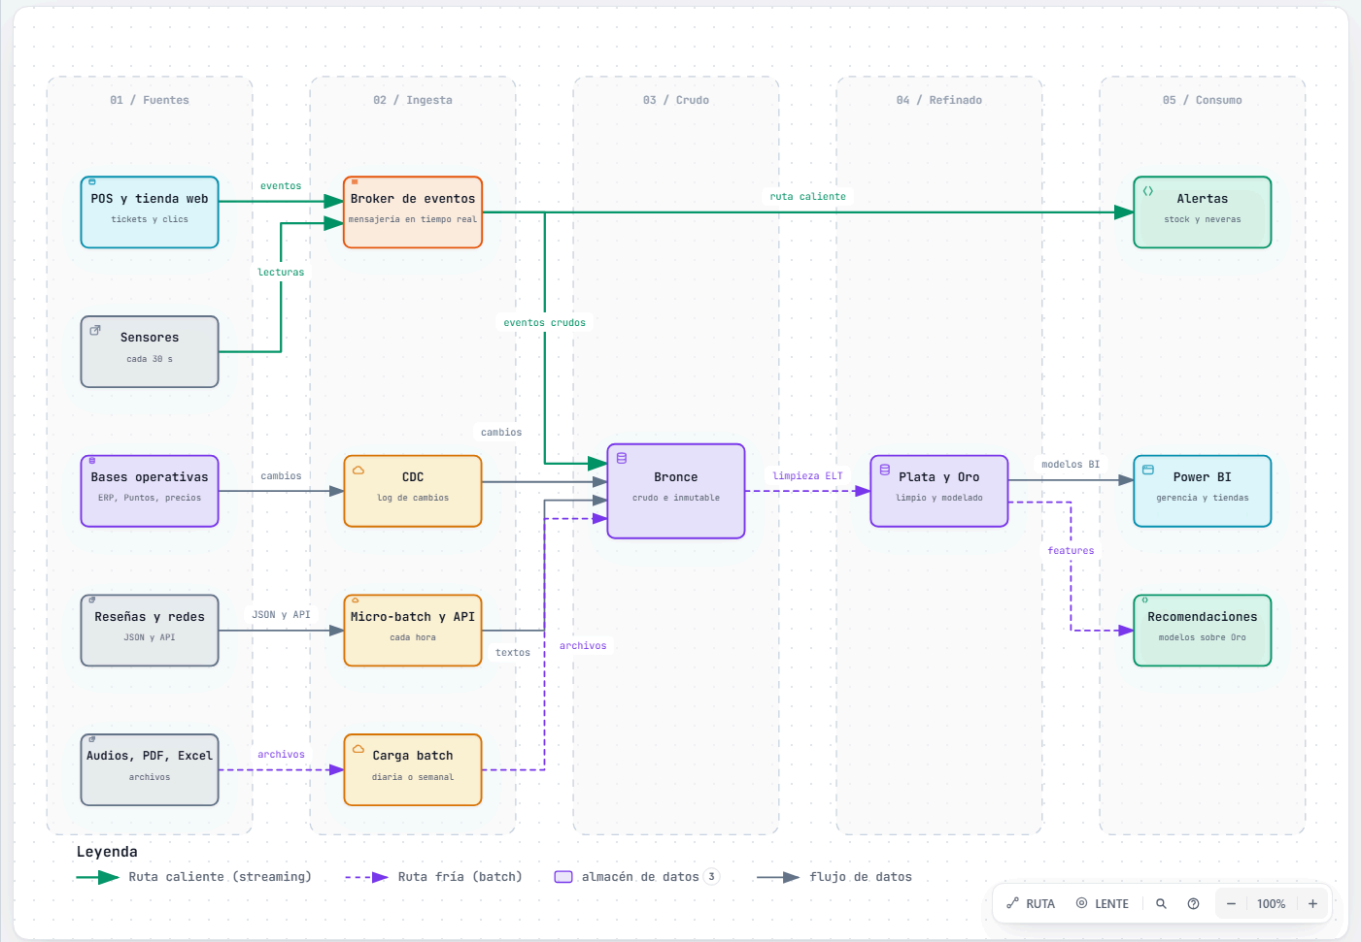
Año 5

Tres países, 200 personas en tecnología y áreas de ventas, logística y mercadeo que piden autonomía.

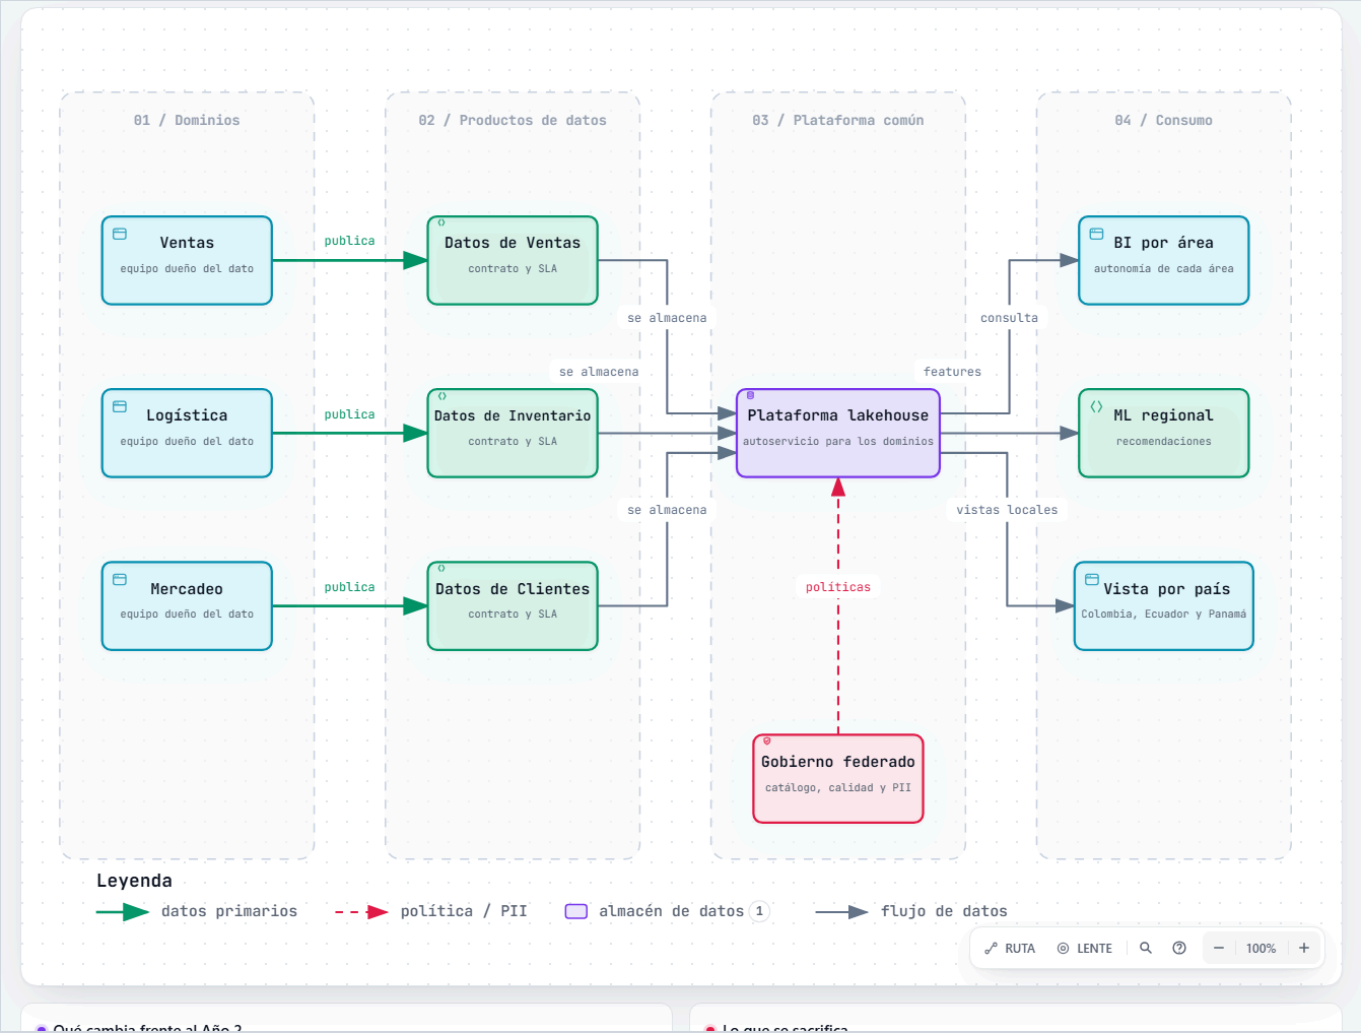
Criterio	Data Warehouse	Data Lake	Lakehouse	Data Mesh
Tipos de dato que necesita la empresa	2	5	5	5
Reportes y BI confiables	4	2	4	4
Soporte para machine learning	2	4	5	4
Gobierno y calidad del dato	3	1	4	4
Costo de almacenamiento y cómputo	2	4	3	3
Tamaño del equipo que puede operarla	3	3	4	5
Autonomía de las áreas de negocio	1	2	3	5
Total	17	21	28	30

Arquitectura ganadora: Data Mesh (30 puntos).

¿Ganó la misma arquitectura? No. Ganó el Data Warehouse hoy, el Lakehouse en el Año 2 y el Data Mesh en el Año 5. Cambiaron tres cosas: los tipos de dato (de ventas tabulares a clics, sensores y texto), el machine learning que antes no existía, y el tamaño del equipo con la autonomía que piden las áreas.



Año 2: lakehouse con ingesta híbrida



Año 5: Data Mesh sobre plataforma común

Anexo D · Hoja de decisión de arquitectura (momento: Año 2)

1. Contexto. Con la tienda en línea, el clickstream, los sensores en todas las neveras y el motor de recomendaciones, RetailNova necesita juntar datos tabulares, JSON y series de tiempo, y servir BI confiable y ML desde un solo lugar con un equipo todavía pequeño.

2. Decisión. Lakehouse con ingesta híbrida: ruta caliente (streaming y CDC) y ruta fría (batch), sobre un único almacenamiento crudo (bronce) con capas plata y oro.

3. Alternativas descartadas.

- **Data Warehouse**: No maneja bien JSON, clics ni series de tiempo, y obligaría a duplicar datos para ML.
- **Data Lake puro**: Daría flexibilidad y bajo costo, pero sin gobierno ni BI confiable se vuelve un pantano de datos.
- **Data Mesh**: Exige equipos de dominio y madurez que RetailNova aún no tiene; sería prematuro con un equipo pequeño.

4. Lo que sacrificamos.

- La simplicidad del warehouse: hay más piezas que operar (broker, CDC, capas).
- Hay que reconciliar la ruta caliente con la fría para que las cifras coincidan.
- Curva de aprendizaje y costo del streaming para un equipo pequeño.

5. Señal para revisar.

- Si el equipo supera unas decenas de personas y las áreas esperan al equipo central para cada dato nuevo, evaluar un mesh.
- Si la operación en Ecuador y Panamá trae reglas de datos distintas por país, evaluar dominios federados.
- Si nadie usa las alertas en tiempo real, volver a batch y recortar el streaming.